

基于图注意力卷积的自注意力机制

学士学位论文答辩

王惟是

北京师范大学大学文理学院

2026 年 5 月 6 日

① 研究背景与意义

目录

- ① 研究背景与意义
- ② 相关工作

目录

- 1 研究背景与意义
- 2 相关工作
- 3 理论基础

目录

- ① 研究背景与意义
- ② 相关工作
- ③ 理论基础
- ④ 方法提出

目录

- ① 研究背景与意义
- ② 相关工作
- ③ 理论基础
- ④ 方法提出
- ⑤ 实验设计

目录

- 1 研究背景与意义
- 2 相关工作
- 3 理论基础
- 4 方法提出
- 5 实验设计
- 6 结果分析

目录

- 1 研究背景与意义
- 2 相关工作
- 3 理论基础
- 4 方法提出
- 5 实验设计
- 6 结果分析
- 7 讨论

目录

- 1 研究背景与意义
- 2 相关工作
- 3 理论基础
- 4 方法提出
- 5 实验设计
- 6 结果分析
- 7 讨论
- 8 结论与未来工作

研究背景：深度学习的发展

- 深度学习在计算机视觉、自然语言处理等领域取得突破性进展




图 1: 典型图结构数据示例

研究背景：深度学习的发展

- 深度学习在计算机视觉、自然语言处理等领域取得突破性进展
- 传统卷积神经网络 (CNN) 在处理网格结构数据方面表现优异




图 1: 典型图结构数据示例

研究背景：深度学习的发展

- 深度学习在计算机视觉、自然语言处理等领域取得突破性进展
- 传统卷积神经网络 (CNN) 在处理网格结构数据方面表现优异
- 现实世界中大量数据呈现非网格结构 (如社交网络、分子结构)




图 1: 典型图结构数据示例

研究背景：深度学习的发展

- 深度学习在计算机视觉、自然语言处理等领域取得突破性进展
- 传统卷积神经网络 (CNN) 在处理网格结构数据方面表现优异
- 现实世界中大量数据呈现非网格结构 (如社交网络、分子结构)
- 图神经网络 (GNN) 应运而生, 成为处理图结构数据的主流方法




图 1: 典型图结构数据示例

研究背景：注意力机制的兴起

- 自注意力机制 (Self-Attention)
由 Transformer 引入




图 2: 自注意力机制基本结构

研究背景：注意力机制的兴起

- 自注意力机制 (Self-Attention) 由 Transformer 引入
- 能够建模序列中任意两个位置之间的依赖关系




图 2: 自注意力机制基本结构

研究背景：注意力机制的兴起

- 自注意力机制 (Self-Attention) 由 Transformer 引入
- 能够建模序列中任意两个位置之间的依赖关系
- 在 NLP 领域取得巨大成功 (如 BERT、GPT)




图 2: 自注意力机制基本结构

研究背景：注意力机制的兴起

- 自注意力机制 (Self-Attention) 由 Transformer 引入
- 能够建模序列中任意两个位置之间的依赖关系
- 在 NLP 领域取得巨大成功 (如 BERT、GPT)
- 如何将自注意力机制与图神经网络有效结合是当前研究热点




图 2: 自注意力机制基本结构

研究意义

理论意义

- 深入理解图注意力卷积与自注意力机制的内在联系
- 探索两种机制融合的理论基础和数学表达
- 为图神经网络的理论发展提供新视角

实际意义

- 提升图神经网络在复杂图结构上的表达能力
- 为社交网络分析、推荐系统、生物信息学等领域提供更强大的工具
- 推动图机器学习技术的实际应用

图神经网络发展历程

- **GCN (2016):** 基于谱域的图卷积




图 3: GNN 发展脉络

图神经网络发展历程

- **GCN (2016)**: 基于谱域的图卷积
- **GraphSAGE (2017)**: 归纳式学习方法




图 3: GNN 发展脉络

图神经网络发展历程

- **GCN (2016)**: 基于谱域的图卷积
- **GraphSAGE (2017)**: 归纳式学习方法
- **GAT (2017)**: 图注意力网络




图 3: GNN 发展脉络

图神经网络发展历程

- **GCN (2016)**: 基于谱域的图卷积
- **GraphSAGE (2017)**: 归纳式学习方法
- **GAT (2017)**: 图注意力网络
- **Transformer-GCN (2019)**: Transformer 与 GCN 结合




图 3: GNN 发展脉络

图注意力机制研究现状

GAT 的局限性

- 仅考虑一阶邻居信息
- 注意力计算复杂度较高
- 缺乏对全局结构的建模能力

自注意力在图上的应用

- Graph Transformer: 将 Transformer 直接应用于图
- GPT-GNN: 生成式图预训练模型
- 现有方法未能充分利用图的局部结构信息

研究空白

如何有效融合图注意力卷积的局部感知能力与自注意力的全局建模能力？

图的数学表示

定义

图 $G = (V, E)$ 由顶点集 $V = \{v_1, v_2, \dots, v_n\}$ 和边集 $E \subseteq V \times V$ 组成。

定义

邻接矩阵 $A \in \mathbb{R}^{n \times n}$ 定义为：

$$A_{ij} = \begin{cases} 1 & \text{若 } (v_i, v_j) \in E, \\ 0 & \text{否则.} \end{cases}$$




图 4: 简单图示例

图卷积神经网络基础


图卷积的一般形式

图卷积层的输出可表示为：

$$\mathbf{H}^{(l+1)} = \sigma \left(\tilde{\mathbf{D}}^{-1/2} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-1/2} \mathbf{H}^{(l)} \mathbf{W}^{(l)} \right)$$

其中：

- $\tilde{\mathbf{A}} = \mathbf{A} + \mathbf{I}$ (添加自环)
- $\tilde{\mathbf{D}}$ 是 $\tilde{\mathbf{A}}$ 的度矩阵
- $\mathbf{W}^{(l)}$ 是第 l 层的权重矩阵
- $\sigma(\cdot)$ 是非线性激活函数



$$\mathbf{H}^{(l+1)} = \sigma(\tilde{\mathbf{D}}^{-1/2} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-1/2} \mathbf{H}^{(l)} \mathbf{W})$$

标准自注意力计算

给定输入序列 $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n]$,
自注意力计算包含三个步骤:

1. ** 投影 ** : 计算 Query、Key、Value

$$\mathbf{Q} = \mathbf{XW}_Q, \quad \mathbf{K} = \mathbf{XW}_K, \quad \mathbf{V} = \mathbf{XW}_V$$

2. ** 注意力得分计算 ** :

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax} \left(\frac{\mathbf{QK}^T}{\sqrt{d_k}} \right) \mathbf{V}$$




图 5: 自注意力计算示意图

多头自注意力


多头注意力机制

为增强模型表达能力，引入多头注意力：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \text{head}_2, \dots, \text{head}_h) \mathbf{W}^O$$

其中每个头的计算为：

$$\text{head}_i = \text{Attention}(Q\mathbf{W}_Q^i, K\mathbf{W}_K^i, V\mathbf{W}_V^i)$$



图注意力卷积自注意力模型框架




图 7: 模型整体框架

核心思想

将图注意力卷积的局部结构感知能力与自注意力的全局依赖建模能力相结合，实现更强大的图表示学习。

图注意力卷积层设计

图注意力卷积公式

对于图中的每个节点 v_i ，其注意力权重计算如下：

$$\alpha_{ij} = \frac{\exp(\text{LeakyReLU}(\mathbf{a}^T[\mathbf{W}\mathbf{h}_i \parallel \mathbf{W}\mathbf{h}_j]))}{\sum_{k \in \mathcal{N}(i)} \exp(\text{LeakyReLU}(\mathbf{a}^T[\mathbf{W}\mathbf{h}_i \parallel \mathbf{W}\mathbf{h}_k]))}$$

其中：

- $\mathbf{a} \in \mathbb{R}^{2d}$ 是注意力权重向量
- $\mathbf{W} \in \mathbb{R}^{d \times d}$ 是线性变换矩阵
- $\mathcal{N}(i)$ 是节点 i 的邻居集合
- $\parallel$ 表示向量拼接操作

图注意力卷积示意图




图 8: 图注意力卷积的邻居聚合过程

图结构感知的自注意力机制

图感知自注意力计算

我们提出一种图结构感知的自注意力机制，其注意力得分计算如下：

$$\mathbf{A}_{att} = \text{softmax} \left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}} \odot \mathbf{M} \right)$$


其中 $\mathbf{M} \in \mathbb{R}^{n \times n}$ 是图结构掩码矩阵，定义为：

$$M_{ij} = \begin{cases} 1 & \text{若 } v_j \text{ 在 } v_i \text{ 的 } k\text{-跳邻居内,} \\ \epsilon & \text{否则 } (\epsilon \text{ 为极小值}) . \end{cases}$$


创新点

通过引入图结构掩码，使自注意力机制能够利用图的拓扑信息，限制注意力范围在合理的邻居范围内。

图感知自注意力与标准自注意力对比



标准自注意力
全连接注意力



图感知自注意力
受限注意力范围

特征融合策略


双路径特征融合

我们采用自适应融合策略整合两条路径的特征：

$$\mathbf{H}_{final} = \lambda \cdot \mathbf{H}_{GAT} + (1 - \lambda) \cdot \mathbf{H}_{SA}$$

其中自适应权重 λ 通过门控机制学习：

$$\lambda = \sigma(\mathbf{W}_g[\mathbf{H}_{GAT} \parallel \mathbf{H}_{SA}] + \mathbf{b}_g)$$



完整模型架构




图 10: 完整的图注意力卷积自注意力模型架构

数据集	节点数	边数	任务类型
Cora	2,708	5,429	节点分类
Citeseer	3,327	4,732	节点分类
PubMed	19,717	88,648	节点分类
Reddit	232,965	11,606,919	节点分类

表 1: 实验数据集统计信息

数据集特性

- Cora/Citeseer/PubMed: 学术论文引用网络
- Reddit: 社交网络数据
- 涵盖不同规模和密度的图结构

对比方法

传统 GNN 方法

- GCN (Kipf et al., 2016)
- GAT (Veličković et al., 2017)
- GraphSAGE (Hamilton et al., 2017)

Transformer 类方法

- Graph Transformer (Yun et al., 2019)
- GPT-GNN (Li et al., 2020)
- Transformer-GCN (Bresson et al., 2020)

评估指标

- 节点分类准确率 (Accuracy)
- 宏平均 F1 分数 (Macro-F1)
- 训练时间和推理时间

实验设置

超参数配置

- 学习率: $1e-3$
- 隐藏层维度: 256
- 注意力头数: 8
- 层数: 3
- Dropout 率: 0.5
- 训练轮数: 200

实验环境

- 硬件: NVIDIA RTX 3090 (24GB)
- 软件: PyTorch 1.10, PyTorch Geometric
- 操作系统: Ubuntu 20.04

节点分类准确率对比

方法	Cora	Citeseer	PubMed	Reddit
GCN	81.5	70.3	79.0	95.2
GAT	83.0	72.5	80.1	95.8
GraphSAGE	82.3	71.8	79.5	95.5
Graph Transformer	82.8	72.0	79.8	95.6
Ours	84.2	73.8	81.5	96.3

表 2: 各方法在不同数据集上的节点分类准确率 (%)

结果分析

我们的方法在所有数据集上均取得最优性能，验证了图注意力卷积与自注意力融合的有效性。

消融实验结果

模型变体	Cora 准确率 (%)	性能下降 (%)
完整模型	84.2	-
移除图注意力卷积	82.1	-2.1
移除自注意力模块	82.5	-1.7
固定融合权重 ($\lambda = 0.5$)	83.0	-1.2
不使用图结构掩码	82.8	-1.4

表 3: 消融实验结果

关键发现

- 图注意力卷积和自注意力模块均对性能有重要贡献
- 自适应融合策略优于固定权重融合
- 图结构掩码有效提升了模型性能




图 11: GAT 注意力分布




图 12: 融合后注意力分布

可视化结论

融合后的注意力机制能够同时捕捉局部紧密连接和全局稀疏依赖，形成更合理的注意力分布。

时间复杂度分析

方法	时间复杂度	Reddit 训练时间 (s/epoch)
GCN	$O(E d)$	2.3
GAT	$O(E d^2)$	4.5
Graph Transformer	$O(n^2d)$	15.8
Ours	$O(E d^2 + knd)$	6.2

表 4: 时间复杂度对比 (k 为邻居范围)

复杂度分析

- 我们的方法复杂度介于 GAT 和 Graph Transformer 之间
- 通过限制注意力范围 (k -跳邻居), 避免了 $O(n^2)$ 的复杂度
- 在保证性能的同时保持了较好的效率

方法优势总结

核心优势

- **表达能力强**: 融合局部和全局信息, 提升模型表达能力
- **效率较高**: 通过图结构掩码限制注意力范围, 控制复杂度
- **自适应融合**: 门控机制自动学习最优融合策略
- **泛化性好**: 在不同规模和类型的数据集上均表现优异

理论贡献

- 建立了图注意力卷积与自注意力机制的统一框架
- 提出了图结构感知的自注意力计算方法
- 证明了融合策略的有效性

当前局限性

- 计算复杂度仍高于传统 GCN
- 超参数（如 k -跳邻居范围）需要手动调整
- 在超大规模图上的扩展性仍需提升

未来改进方向

- 探索更高效的注意力计算方法（如稀疏注意力）
- 研究自适应邻居范围选择机制
- 结合图采样技术提升大规模图处理能力

研究结论

主要贡献

- 提出了一种基于图注意力卷积的自注意力机制（GA-SA）
- 设计了图结构感知的自注意力计算方法
- 引入自适应门控融合策略整合局部和全局特征
- 在多个基准数据集上验证了方法的有效性

核心发现

图注意力卷积与自注意力机制的有效融合能够显著提升图表示学习的性能，为图神经网络的发展提供了新的思路。

未来工作展望

短期目标

- 在更多真实场景数据集上验证方法
- 探索与其他 GNN 变体的结合
- 优化模型训练效率

长期目标

- 研究动态图上的注意力机制
- 探索图预训练与下游任务的结合
- 推动方法在实际应用中的落地

-  Thomas N. Kipf and Max Welling.
Semi-Supervised Classification with Graph Convolutional Networks.
ICLR, 2017.
-  Petar Veličković, Guillem Cucurull, Arantxa Casanova, Adriana Romero, Pietro Liò, and Yoshua Bengio.
Graph Attention Networks.
ICLR, 2018.
-  William L. Hamilton, Rex Ying, and Jure Leskovec.
Inductive Representation Learning on Large Graphs.
NIPS, 2017.
-  Seongjun Yun, Minbyul Jeong, Raehyun Kim, Jaewoo Kang, and Hyunwoo J. Kim.
Graph Transformer Networks.
NeurIPS, 2019.

感谢观看！

联系方式

- 作者：王惟是
- 邮箱：202211079012@mail.bnu.edu.cn
- 论文链接：待发表